

Token: model không đọc "từ", model đọc mảnh chữ

Model không nhìn từ nguyên vẹn. Nó cắt văn bản thành các **mảnh nhỏ gọi là token**: có từ là một mảnh, có từ vỡ ba bốn mảnh, cả dấu câu và khoảng trắng cũng là mảnh.

Ví dụ: *"Hello world"* $\approx$ 2 token, nhưng *"Xin chào"* có thể tới 3–4 token.


Tiếng Việt, code, JSON tốn token hơn tiếng Anh thường — vì dấu thanh, ký tự đặc biệt và cấu trúc bị cắt nhỏ ra.

Độ dài câu XẤP XỈ nhau (9 vs 10 từ) nhưng tokenizer GPT cắt Tiếng Việt vụn hơn hẳn: 1.9 token/từ so với 1.2 token/từ
So sánh KHÔNG cùng số từ tuyệt đối (9 vs 10) — điểm quan trọng là tỉ lệ token/từ, không phải tổng số từ.

Tiếng Anh: "To date, the cleverest thinker of all time was" → 9 từ → 11 token



Tiếng Việt: "Lan bỏ quyển sách vào túi vì nó quá dày" → 10 từ → 19 token



Mình họa bằng tokenizer thật: tiktoken c100k_base (GPT-4). Ô vàng = một "từ" bị cắt thành nhiều token — vd "cleverest" → "clever" + "est"; "Lan" → "L" + "an" (dấu thanh tiếng Việt buộc BPE tách nhỏ hơn vì được huấn luyện chủ yếu trên dữ liệu Anh ngữ).
Nguồn: OpenAI tiktoken (c100k_base), tính trực tiếp trong phiên này.

Mọi thứ model làm đều quy ra token — và mỗi token đều có giá. Nhớ điều này khi sang phần chi phí.