


AI, ML, Deep Learning, GenAI, LLM — nằm ở đâu trong cùng một hệ?

từ rộng đến hẹp



- **AI** — chiếc ô lớn nhất: mọi hệ thống có yếu tố “thông minh”.
- **Machine learning** — học từ dữ liệu thay vì viết luật tay.
- **Deep learning** — mạng nơ-ron nhiều tầng tự học đặc trưng.
- **Generative AI** — sinh nội dung mới: văn bản, ảnh, code.
- **LLM** — model nền chuyên ngôn ngữ, tim của làn sóng hiện nay.

LLM không phải toàn bộ AI — nhưng nó là tầng nền của gần hết trải nghiệm AI bạn dùng hôm nay

Ba nhóm AI chính: phân loại · sinh nội dung · hành động

Discriminative AI

Giỏi **phân loại, dự đoán**: lọc spam, phát hiện gian lận, nhận diện ảnh.

Input → một nhãn, một con số

Generative AI

Sinh ra thứ mới: văn bản, ảnh, code.
ChatGPT, Claude, Midjourney.

Prompt → nội dung mới

Agentic AI


Nhận **mục tiêu** rồi tự làm nhiều bước:
lập kế hoạch, dùng công cụ, hành động.

Goal → Plan → Action

*LLM là **engine chung** của cả Generative lẫn Agentic — cuối buổi sáng mình sẽ thấy agent khác LLM ở đâu*

2017: Transformer

Attention Is All You Need




Transformer là bước ngoặt vì nó cho mô hình hiểu ngôn ngữ theo cách linh hoạt hơn: **mỗi từ có thể nhìn sang những từ quan trọng khác** trong cả câu, thay vì chỉ đi tuần tự từng bước → trở thành nền móng kỹ thuật cho GPT, BERT và toàn bộ làn sóng LLM sau đó.

LLM là gì? — một bộ não nền, không phải một chatbot

LLM (Large Language Model) là một mô hình ngôn ngữ rất lớn, thường dựa trên kiến trúc Transformer, được luyện trên hàng nghìn tỷ mảnh chữ để học cách **đoán mảnh chữ tiếp theo trong ngữ cảnh**.


Nhờ được luyện đủ rộng, nó trở thành một **nền chung**: thay vì mỗi việc train một model riêng, cùng một model làm được rất nhiều việc.

Chatbot chỉ là **một dạng sản phẩm** đóng gói quanh bộ não đó — lớp áo bên ngoài.



LLM = bộ não ngôn ngữ dùng chung cho mọi việc — sản phẩm bạn thấy chỉ là lớp áo bên ngoài

Bên trong Transformer: đầu ra luôn là một phân bố xác suất



Với mọi ngữ cảnh, model chấm điểm **MỌI** từ trong từ vựng — “land” 22%, “forest” 9%... — rồi chọn theo xác suất đó

Token: model không đọc "từ", model đọc mảnh chữ

Model không nhìn từ nguyên vẹn. Nó cắt văn bản thành các **mảnh nhỏ gọi là token**: có từ là một mảnh, có từ vỡ ba bốn mảnh, cả dấu câu và khoảng trắng cũng là mảnh.

Ví dụ: *"Hello world"* $\approx$ 2 token, nhưng *"Xin chào"* có thể tới 3–4 token.

Tiếng Việt, code, JSON tốn token hơn tiếng Anh thường — vì dấu thanh, ký tự đặc biệt và cấu trúc bị cắt nhỏ ra.

Độ dài câu XẤP XỈ nhau (9 vs 10 từ) nhưng tokenizer GPT cắt Tiếng Việt vụn hơn hẳn: 1.9 token/từ so với 1.2 token/từ
So sánh KHÔNG cùng số từ tuyệt đối (9 vs 10) — điểm quan trọng là tỉ lệ token/từ, không phải tổng số từ.

Tiếng Anh: "To date, the cleverest thinker of all time was" → 9 từ → 11 token



Tiếng Việt: "Lan bỏ quyển sách vào túi vì nó quá dày" → 10 từ → 19 token



Mình họa bằng tokenizer thật: tiktoken c100k_base (GPT-4). Ô vàng = một "từ" bị cắt thành nhiều token — vd "cleverest" → "clever" + "est"; "Lan" → "L" + "an" (dấu thanh tiếng Việt buộc BPE tách nhỏ hơn vì được huấn luyện chủ yếu trên dữ liệu Anh ngữ).
Nguồn: OpenAI tiktoken (c100k_base), tính trực tiếp trong phiên này.

Mọi thứ model làm đều quy ra token — và mỗi token đều có giá. Nhớ điều này khi sang phần chi phí.



Context: bàn làm việc có hạn của model

Mỗi lần trả lời, model chỉ nhìn được một lượng chữ có hạn — gọi là **context**. Hãy hình dung một **bàn làm việc**: mọi thứ muốn model "thấy" phải bày lên bàn.

Quy đổi: 128K token $\approx$ một cuốn sách 300 trang; 1M token $\approx$ 4–5 cuốn sách trên bàn cùng lúc.

Bàn đầy quá thì đồ ở **giữa bàn dễ bị bỏ sót** — đặt điều quan trọng ở giữa một prompt rất dài, model có thể "quên" mất.

Vì sao "nhỏ" thật nhiều vào prompt không phải lúc nào cũng tốt



Context càng dài càng tốn tiền và càng chậm — bàn rộng không có nghĩa là dùng tốt

Attention: mỗi từ được “nhìn sang” những từ quan trọng khác

Thay vì đọc tuần tự từng chữ, cơ chế **attention** cho phép mỗi token:

- **Chủ động “quay đầu”** nhìn lại các token trước đó trong câu
- **Chấm điểm mức độ liên quan** của từng token đối với nghĩa của mình
- **Khóa nghĩa theo ngữ cảnh** — “nó” là quyển sách hay cái túi, tùy theo nó chú ý vào từ nào

Đây chính là chữ T trong GPT — và là lý do model hiểu ngữ cảnh tốt hơn hẳn các thế hệ trước

Video minh họa: [Attention in transformers, step-by-step - 3Blue1Brown](#)